

---

---

# Introdução ao MCMC

Com mais equações, admito



---

---

# Como calcular as posteriores?




- Nos casos que vimos até agora, é simples analisar e tirar conclusões a partir da distribuição dos parâmetros
  - Isso nem sempre é verdade
  - Quando isso acontece, apelamos para métodos computacionais
-

# Método força bruta



---

# Método força bruta em alta dimensionalidade não funciona



---

# Objetivo geral de um método de amostragem

- Ao invés de calcular a posterior em todas as possibilidades de um parâmetro, vamos tentar amostrar só as que têm probabilidade posterior alta

---

# Objetivo geral de um método de amostragem

- Ao invés de calcular a posterior em todas as possibilidades de um parâmetro, vamos tentar amostrar só as que têm probabilidade posterior alta
  - Ao invés de ter uma expressão fechada para a posterior, vamos ter um monte de valores, com proporção igual às probabilidades da posterior
-


---

# Amostra da posterior

$$\{\theta_1, \theta_2, \theta_3, \dots\} \sim P(\theta|y)$$



$$E[\theta] = \frac{1}{N} \sum_{i=1}^N \theta_i$$



---

# Como fazer uma amostra?

- Distribuições simples podem ser amostradas usando um gerador de números aleatórios e um pouco de matemática.
  - Normal, binomial, Poisson, ... todas são bem simples e podem ser usadas como blocos para montar distribuições mais complicadas. (todas as funções *algumacoisa* do R)
-




---

# Como fazer uma amostra?

- Distribuições simples podem ser amostradas usando um gerador de números aleatórios e um pouco de matemática.
  - Normal, binomial, Poisson, ... todas são bem simples e podem ser usadas como blocos para montar distribuições mais complicadas. (todas as funções *algumacoisa* do R)
  - **Quando não tem jeito fácil, usamos MCMC.**
-

---

# Reino do Bom Rei Markov



- Cada ilha tem população proporcional ao seu número
  - O Bom Rei quer visitar todas as ilhas, mas passar em cada uma uma quantidade de tempo que seja proporcional à população
  - O Rei tem preguiça de montar um cronograma, então ele desenvolveu um conjunto de regras para suas viagens
-

---

# O algoritmo do Rei Markov

1. Toda semana o Rei decide se ele vai viajar para alguma das ilhas vizinhas ou adiar a viagem. Para decidir, ele joga uma moeda. Se der cara ele considera ir para a ilha que está no sentido horário, se der coroa no sentido anti horário.
  2. Decidida a direção, ele decide se vai viajar ou ficar. Para isso, ele pega um número de conchas proporcional à população da ilha para a qual ele pode ir. Depois, ele pega um número de pedras proporcional à população da ilha que ele está.
  3. Se ele tiver mais conchas que pedras, ele viaja. Se não, ele joga fora um número de pedras igual ao número de conchas e coloca a pedra e as conchas que sobraram num saco. Depois, ele sorteia desse saco. Se der concha ele muda de ilha.
-



```
num_weeks <- 1e5
positions <- rep(0,num_weeks)
current <- 10
for ( i in 1:num_weeks ) {
  # record current position
  positions[i] <- current
  # flip coin to generate proposal
  proposal <- current + sample( c(-1,1) , size=1 )
  # now make sure he loops around the archipelago
  if ( proposal < 1 ) proposal <- 10
  if ( proposal > 10 ) proposal <- 1
  # move?
  probab_move <- proposal/current
  current <- ifelse( runif(1) < probab_move , proposal ,
    current )
}
plot(table(positions))
```

---

---

# O algoritmo de Metropolis

1. Começa com qualquer valor do(s) parâmetro(s)
  2. Sorteia uma mudança no parâmetro.
  3. Decidido qual a mudança candidata, verificamos se a probabilidade posterior aumentou ou diminuiu.
  4. Se a probabilidade posterior aumentou, aceitamos o novo parâmetro. Se diminuiu, aceitamos o novo parâmetro com probabilidade igual a razão entre a probabilidade posterior candidata e a atual.
-


---

# Por que essa maluquice funciona?

- A ideia é montar uma cadeia de Markov que tenha como estado estacionário a distribuição alvo
  - A escolha da probabilidade de transição usando a razão de probabilidades posteriores garante que a cadeia chegue na distribuição desejada
  - Se a cadeia respeitar alguns pré-requisitos, ela converge para a distribuição que queremos.
    - Ergodicidade
    - Balanço detalhado
-

---

# Caminhando no espaço de parâmetros



---

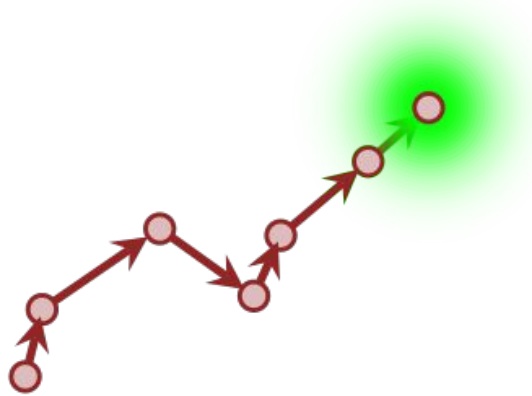
# Caminhando no espaço de parâmetros





---

# Caminhando no espaço de parâmetros



---

# Transição de Metropolis

$$\theta_0 \rightarrow \theta_1 \rightarrow \theta_2 \rightarrow \cdots \sim P(\theta|y)$$

---

---

# Transição de Metropolis

$$\theta_0 \rightarrow \theta_1 \rightarrow \theta_2 \rightarrow \cdots \sim P(\theta|y)$$

Distribuição da

proposta:  $\theta^* \sim q(\theta^*|\theta_{t-1})$

---

---

# Transição de Metropolis

$$\theta_0 \rightarrow \theta_1 \rightarrow \theta_2 \rightarrow \dots \sim P(\theta|y)$$

Distribuição da  
proposta:  $\theta^* \sim q(\theta^*|\theta_{t-1})$

Caso onde a distribuição é simétrica:

$$q(\theta^*|\theta_{t-1}) = q(\theta_{t-1}|\theta^*)$$

---

---

# Transição de Metropolis

$$\theta_0 \rightarrow \theta_1 \rightarrow \theta_2 \rightarrow \dots \sim P(\theta|y)$$

Distribuição da  
proposta:  $\theta^* \sim q(\theta^*|\theta_{t-1})$

Caso onde a distribuição é simétrica:

$$q(\theta^*|\theta_{t-1}) = q(\theta_{t-1}|\theta^*)$$

Probabilidade de aceitar  
a proposta:  $P(\theta_t \leftarrow \theta^*) = \min(1, \frac{P(\theta^*|y)}{P(\theta_{t-1}|y)})$

---

---

# Transição de Metropolis-Hastings

$$\theta_0 \rightarrow \theta_1 \rightarrow \theta_2 \rightarrow \dots \sim P(\theta|y)$$

Distribuição da  
proposta:  $\theta^* \sim q(\theta^*|\theta_{t-1})$

Caso onde a distribuição não é simétrica:

$$q(\theta^*|\theta_{t-1}) \neq q(\theta_{t-1}|\theta^*)$$

Probabilidade  
de aceitar a  
proposta:

$$P(\theta_t \leftarrow \theta^*) = \min\left(1, \frac{P(\theta^*|y)}{P(\theta_{t-1}|y)} \frac{q(\theta_{t-1}|\theta^*)}{q(\theta^*|\theta_{t-1})}\right)$$

---

---

# Condições de convergência

$$P(\theta|y) \sum_{\theta' \neq \theta} P(\theta'|\theta) = \sum_{\theta' \neq \theta} P(\theta'|y) P(\theta|\theta')$$

- Ergodicidade:
    - Todos os estados têm que ser possíveis de serem acessados. Não importa de onde vc começa, depois de um número suficiente de passos vc pode estar em qualquer lugar.
    - Difícil de provar.
    - Se a cadeia é ergótica, a distribuição estacionária é única.
-

---

# Condição forte de convergência



$$P(\theta|y)P(\theta'|\theta) = P(\theta'|y)P(\theta|\theta')$$

- Balanço detalhado:
    - Condição barra pesada.
    - Fácil de provar.
    - Garante unicidade da distribuição estacionária.
-





---

# MCMC ideal




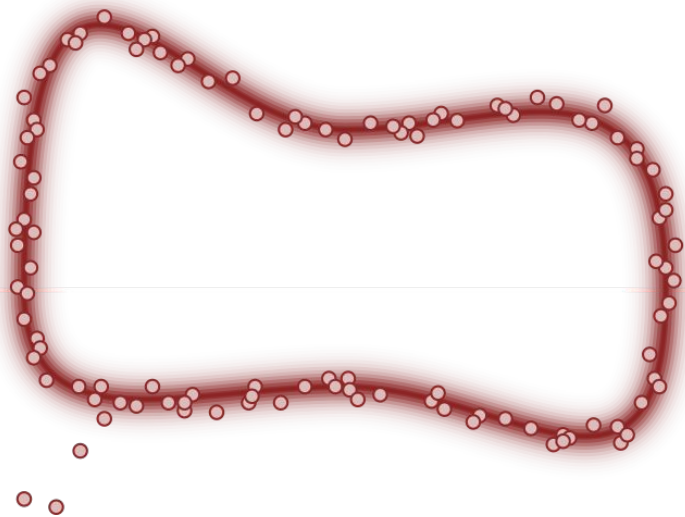
---

# MCMC ideal




---

# MCMC ideal




MH with  $N(0, 1.000^2)$  proposal



(a)

MH with  $N(0, 500.000^2)$  proposal



(b)

MH with  $N(0, 8.000^2)$  proposal

