

# Rumo ao desconhecido ...



# Rumo ao desconhecido ...

Embora para modelos mais simples seja possível derivar a distribuição posterior diretamente, sem o uso de simulações.


Usamos o MCMC pois não podemos derivar diretamente a posterior. A estimativa da posterior usando MCMC é como a exploração da superfície de um planeta desconhecido.



# Rumo ao desconhecido ...


Técnicas usadas para explorar o desconhecido?

---



# Rumo ao desconhecido ...


Técnicas usadas para explorar o desconhecido?



*Mass Effect II*

# Rumo ao desconhecido ...

Técnicas usadas para explorar o desconhecido?




"Dorothy IV"  
- *Twister* (1996)

# Rumo ao desconhecido ...

Técnicas usadas para explorar o desconhecido?



3D holo drones  
- *Prometheus* (2012)



# Regras de exploração


## Características do MCMC

*Bayesian monster*

Type: Construct / Outsider


Alignment: L/N

Quote: "I shall walk..."



*Seu mundo é visto pelos olhos da função de likelihood.  
Existem lendas sobre esse mundo que podem lhe guiar.  
Sua memória é curta, somente lembra o último passo.  
Ele sempre escala ao alto, mas as vezes desce alguns passos.*

# Regras de exploração



Um algoritmo é como um fluxograma

O **MCMC** segue um algoritmo.  
Os passos seguem uma  
ordem definida.

Alguns passos são sempre efetuados -- ●

Outros dependem de certas condições -- •

# Visão geral do algoritmo

1) Selecione um ponto de partida,  $\theta^0$ . *Metropolis algorithm*

2) Repita por  $n$  gerações:

2.1) Faça uma proposta de um novo valor para  $\theta^*$ .

2.2) Calcule a *odds ratio*:

$$r = \frac{P(\theta^* | y)}{P(\theta^{t-1} | y)}$$

2.3) Defina:

$$\theta^t = \begin{cases} \theta^* \text{ com probabilidade } \min(r, 1) \\ \theta^{t-1} \text{ do contrario.} \end{cases}$$

2.4) Salve  $\theta^t$  em algum lugar.


3)  $P(\theta | y) \sim$  histograma de  $\{\theta^{t=1}, \theta^{t=2}, \dots, \theta^{t=n}\}$

# MCMC passo a passo

1) Selecione um ponto de partida,  $\theta^0$ .

- O ponto de partida deve ter valor de verossimilhança maior que zero.

$$P(\theta^0 | y) > 0$$



Valor inicial de verossimilhança com likelihood  $< 0$  é um motivo comum para uma cadeia de MCMC não iniciar!

Lembrando que vamos trabalhar com o log(likelihood).



# MCMC passo a passo

1) Selecione um ponto de partida,  $\theta^0$ .

- O ponto de partida deve ter valor de verossimilhança maior que zero.

$$P(\theta^0 | y) > 0$$

- O ponto de partida também deve ter valor existente de prior, ou seja, estar dentro da distribuição do prior.



# MCMC passo a passo

1) Selecione um ponto de partida,  $\theta^0$ .

- O ponto de partida deve ter valor de verossimilhança maior que zero.

$$P(\theta^0 | y) > 0$$

- O ponto de partida também deve ter valor existente de prior, ou seja, estar dentro da distribuição do prior.

- Recomendações:

1) Rodar cadeias com diferentes  $\theta^0$ .

2) Escolher  $\theta^0$  com base em uma estimativa rápida, como o ML.

3) Gerar  $\theta^0$  da distribuição do prior.

# Visão geral do algoritmo

1) Selecione um ponto de partida,  $\theta^0$ . *Metropolis algorithm*

2) Repita por  $n$  gerações:

    2.1) Faça uma proposta de um novo valor para  $\theta^*$ .

    2.2) Calcule a *odds ratio*:

$$r = \frac{P(\theta^* | y)}{P(\theta^{t-1} | y)}$$

    2.3) Defina:

$$\theta^t = \begin{cases} \theta^* \text{ com probabilidade } \min(r, 1) \\ \theta^{t-1} \text{ do contrario.} \end{cases}$$

2.4) Salve  $\theta^t$  em algum lugar.

3)  $P(\theta | y) \sim$  histograma de  $\{\theta^{t=1}, \theta^{t=2}, \dots, \theta^{t=n}\}$

# MCMC passo a passo

O ponto de partida ( $\theta^0$ ) é o início de nossa cadeia.

Como o algoritmo caminha pela superfície de likelihood?



$$\theta^0 \longrightarrow \theta^*$$

$$10 + \text{unif}(-1, +1) = 9.8$$

$$\theta^0 \longrightarrow \theta^*$$


# MCMC passo a passo

O ponto de partida ( $\theta^0$ ) é o início de nossa cadeia.

Como o algoritmo caminha pela superfície de likelihood?



$$\theta^0 \longrightarrow \theta^*$$



# MCMC passo a passo

A distribuição de proposta gera uma quantidade que é adicionada ao valor atual do parâmetro  $\theta^t$ , formando o  $\theta^*$ , ou *valor proposta*.



$$\theta^0 \longrightarrow \theta^*$$

Distribuição de proposta  
(*proposal distribution*)

The diagram illustrates the transition from the current parameter value  $\theta^0$  to the proposed value  $\theta^*$ . A red bracket labeled "Distribuição de proposta (proposal distribution)" encloses the expression  $unif(-1, +1)$ . An arrow points from  $\theta^0$  to the right, with a dashed red oval enclosing the addition operation  $+ unif(-1, +1)$ . The result of this addition is shown as  $= 9.8$ , indicating the proposed new value  $\theta^*$ .


$$10 + unif(-1, +1) = 9.8$$
$$\theta^0 \longrightarrow \theta^*$$

# MCMC passo a passo

A distribuição de proposta gera uma quantidade que é adicionada ao valor atual do parâmetro  $\theta^t$ , formando o  $\theta^*$ , ou *valor proposta*.

$$\begin{aligned}\theta^t + \text{unif}(\min, \max) &= \theta^* \\ \theta^t + \text{norm}(\mu = \theta^t, \sigma^2) &= \theta^*\end{aligned}$$

entre outras ...



# MCMC passo a passo

A distribuição de proposta gera uma quantidade que é adicionada ao valor atual do parâmetro  $\theta^t$ , formando o  $\theta^*$ , ou *valor proposta*.

---

Importante notar que o novo valor de parâmetro deve pertencer ao conjunto de valores possíveis para o parâmetro.

Por exemplo,  $\sigma^2 = [0, \infty)$

Nesses casos temos que usar estratégias para propor novos valores dentro dos valores possíveis.

# Visão geral do algoritmo

1) Selecione um ponto de partida,  $\theta^0$ . *Metropolis algorithm*

2) Repita por  $n$  gerações:

2.1) Faça uma proposta de um novo valor para  $\theta^*$ .

2.2) Calcule a *odds ratio*:

$$r = \frac{P(\theta^* | y)}{P(\theta^{t-1} | y)}$$

2.3) Defina:

$$\theta^t = \begin{cases} \theta^* \text{ com probabilidade } \min(r, 1) \\ \theta^{t-1} \text{ do contrario.} \end{cases}$$


2.4) Salve  $\theta^t$  em algum lugar.

3)  $P(\theta | y) \sim$  histograma de  $\{\theta^{t=1}, \theta^{t=2}, \dots, \theta^{t=n}\}$

# MCMC passo a passo

Agora temos o valor de parâmetro  $\theta^t$  e a proposta  $\theta^*$ .

Precisamos decidir se aceitamos  $\theta^*$  e caminhamos um passo na cadeia ou se rejeitamos  $\theta^*$  e ficamos no mesmo lugar.




Se o valor proposta tiver **melhor** fit que o valor atual, então **aceitamos**  $\theta^*$ .

Se o valor proposta tiver **pior** fit que o valor atual, então **rejeitamos**  $\theta^*$  com uma certa probabilidade.


# MCMC passo a passo

Se o valor proposta tiver **melhor** fit que o valor atual, então **aceitamos**  $\theta^*$ .



*Sempre  
aceito!*

*Aceito com  
chance igual a r  
(odds ratio)*





Se o valor proposta tiver **pior** fit que o valor atual, então **rejeitamos**  $\theta^*$  com uma certa probabilidade.

# MCMC passo a passo

$$r = \frac{P(\theta^* | y)}{P(\theta^{t-1} | y)}$$

$$r \geq 1$$

Aceito com  
chance igual a  $r$   
(odds ratio)



Sempre  
aceito!

$0 < r < 1$   
 $P(\text{aceite}) \sim r$

# MCMC passo a passo

$$r = \frac{P(\theta^* | y)}{P(\theta^{t-1} | y)}$$

*Aceito com  
chance igual a  $r$   
(odds ratio)*




$$0 < r < 1$$


$P(\text{aceite}) \sim r$

Aceitar um passo para "baixo" é uma característica fundamental do MCMC. Isso possibilita que o algoritmo faça amostragens da distribuição posterior mesmo quando existem múltiplos ótimos locais.

# MCMC passo a passo



poor mixing



good mixing

Se nenhuma proposta for aceita a cadeia pode ficar no mesmo lugar por várias gerações. Pois os valores de proposta são muito piores que o valor atual.

Isso é chamado de *poor mixing* da cadeia.

# Visão geral do algoritmo

1) Selecione um ponto de partida,  $\theta^0$ . *Metropolis algorithm*

2) Repita por  $n$  gerações:

2.1) Faça uma proposta de um novo valor para  $\theta^*$ .

2.2) Calcule a *odds ratio*:

$$r = \frac{P(\theta^* | y)}{P(\theta^{t-1} | y)}$$

2.3) Defina:


$$\theta^t = \begin{cases} \theta^* \text{ com probabilidade } \min(r, 1) \\ \theta^{t-1} \text{ do contrario.} \end{cases}$$



2.4) Salve  $\theta^t$  em algum lugar.

3)  $P(\theta | y) \sim$  histograma de  $\{\theta^{t=1}, \theta^{t=2}, \dots, \theta^{t=n}\}$

# MCMC passo a passo



# Visão geral do algoritmo

1) Selecione um ponto de partida,  $\theta^0$ . *Metropolis algorithm*

2) Repita por  $n$  gerações:

2.1) Faça uma proposta de um novo valor para  $\theta^*$ .

2.2) Calcule a *odds ratio*:

$$r = \frac{P(\theta^* | y)}{P(\theta^{t-1} | y)}$$

2.3) Defina:

$$\theta^t = \begin{cases} \theta^* \text{ com probabilidade } \min(r, 1) \\ \theta^{t-1} \text{ do contrario.} \end{cases}$$

2.4) Salve  $\theta^t$  em algum lugar.

► 3)  $P(\theta | y) \sim \text{histograma de } \{\theta^{t=1}, \theta^{t=2}, \dots, \theta^{t=n}\}$

# MCMC passo a passo


write  $\theta^t$

vai gerar  $\{\theta^{t=0}, \theta^{t=1}, \dots, \theta^{t=n}\}$

Após retirar o "burnin" (opcional), a série de valores geradas pelo MCMC são as amostras proporcionais à distribuição posterior do modelo.

Usamos essas amostras para explorar a frequência de cada valor de  $\theta_i$  na posterior.


# MCMC passo a passo



$$P(\theta|y) \text{ & } P(\theta|y) \sim hist(\theta^{t=0}, \theta^{t=1}, \dots, \theta^{t=n})$$

# MCMC passo a passo

O gráfico da verossimilhança em função das gerações também é bastante explorado. Aqui podemos verificar se a cadeia tem um bom *mixing*.



# MCMC passo a passo

Agora vamos trabalhar esses conceitos com exemplos.

Vamos também explorar como o algoritmo de Metropolis é usado para estimar parâmetros de modelos comparativos filogenéticos.

Próximo passos:

- Metropolis-Hastings algorithm**
- Exemplos com PCMs**
- Análise da posterior estimada**  
(burnin, convergência e etc...)